

Universidade do Minho
UC: Análise de Tráfego de Rede
TP2 - Anonimização de Tráfego e Detecção de Anonimizadores
Ano Lectivo 2025/2026 — MCS — 2º Sem

1. Descrição geral

Este exercício foca-se no "braço de ferro" entre a privacidade e a segurança operacional. Os alunos deverão transformar um dataset bruto em versões anonimizadas e, simultaneamente, desenvolver algoritmos capazes de identificar tráfego anonimizado (Tor, VPN, I2P, etc.) mesmo quando os metadados críticos foram ofuscados. Dataset: PCAP gerado contendo tráfego misto (Legítimo + Tor/VPN).

2. Tarefas Específicas

Semana 1: Pipeline de Anonimização e Métricas de Dispersão

O objetivo é transformar o dataset original utilizando diferentes modelos de preservação de prefixos. Utilize ferramentas específicas de anonimização para processar o tráfego bruto e gerar versões anonimizadas.

Implementação de Níveis. Crie pelo menos três PCAPs anonimizados a partir do original, variando os parâmetros: (ex.: níveis de prefix preservation ou chaves criptográficas).

- **N1 (Básica):** Anonimização total de IPs (Random mapping).
- **N2 (Prefix-Preserving):** Utilizando tcpdpriv ou CryptoPan (com chave) para preservar os primeiros 16 e 24 bits.
- **N3 (Avançada):** Anonimização de campos de aplicação (Payload e Portas) via FLAIM/tcpmpkpub.

Questões de Análise:

- **Variabilidade da Entropia:** Calcule a Entropia de Shannon para os endereços IP de origem antes e depois de cada nível de anonimização. Como é que a preservação de prefixos (16 vs 24 bits) influencia a dispersão estatística dos dados?
- **Medição de k-Anonymity:** Identifique o valor de k para as subnets mais frequentes no dataset. Quantos hosts permanecem distinguíveis após a aplicação da técnica de prefix-preserving?

- **Rigor Criptográfico:** No caso do CryptoPan, qual a importância técnica da utilização de uma chave simétrica em comparação com tabelas de mapeamento estáticas (tcpdpriv) em termos de ataques de frequência?

Semana 2: Detecção de Anonimizadores e Perda de Utilidade

O foco muda para a identificação de protocolos que usam anonimização nativa (Tor, VPN, I2P) e como as técnicas da Semana 1 afetam essa detecção. Avalie as versões anonimizadas utilizando métricas quantitativas em Python (Pandas/Scipy).

- **Classificador de Tráfego:** Desenvolver um modelo em Python (scikit-learn) que utilize apenas features temporais e de volume (Packet Size, IAT) para identificar tráfego Tor e VPN.
- **Teste de Resiliência:** Testar a precisão do modelo nos PCAPs anonimizados na Semana 1.
- **Visualização:** Gere gráficos comparativos (ex.: boxplots de entropia pré/pós-anonimização) para ilustrar o trade-off entre privacidade e utilidade.

Questões de Análise:

- **Fingerprinting de Protocolos:** Quais são as 3 principais features (ex: MTU fixo em VPNs, padrões de células de 512 bytes no Tor) que permitem detetar estes protocolos mesmo quando o IP está anonimizado?
- **Impacto da Anonimização na Detecção:** Apresente uma tabela comparativa com as métricas de Accuracy, F1-Score e Precision do teu classificador nos 4 cenários (Original, L1, L2, L3). Qual a métrica de fluxo que sofre maior degradação após a anonimização avançada?
- **Trade-off Privacidade vs. Utilidade:** Através de um gráfico de dispersão (Scatter Plot), ilustre o ponto de equilíbrio onde a anonimização é suficiente para proteger a identidade, mas ainda permite que um sistema de IDS detete o uso de Tor

3. Recursos e Ferramentas

- **Datasets Recomendados:** ISCX-VPN-NonVPN-2016 CIC-Darknet2020 UNSW-NB15, MAWI Archive, ISCX-IDS-2012 ou CICIoT2023.
- **Stack Tecnológica:** tcpdpriv, CryptoPan, tcpmkpub/FLAIM, Tor/I2P clients, Wireshark/tshark, tcprewrite, TraceWrangler, Zeek (scripts personalizados), Python (Pandas, Scipy, scikit-learn, Matplotlib/Seaborn).
- **Restrição de IA:** O uso de LLMs para a geração de respostas ou análises principais é **proibido**, visando o desenvolvimento de competências práticas diretas.

4. Entregáveis

O Jupyter Notebook, **ou** Relatório Técnico, e incluir:

1. **Metodologia:** Pipeline de anonimização e injeção de tráfego com ferramentas específicas.
2. **Análise de Anonimização:** Análise de Anonimização: Avaliação quantitativa de privacidade e utilidade com visualizações (gráficos comparativos, histogramas).
3. **Dossier de Detecção:** Descrição de cada tipo de tráfego anonimizado, modelo de classificador e métricas de precisão pré/pós-anonimização.
4. **Código Fonte:** Jupyter Notebook reproduzível.

Em alternativa ao relatório é aceite apenas o Jupyter Notebook, ou equivalente, devidamente documentado e incluindo os itens referidos.

5. Critérios de Avaliação

- **Correção Técnica (40%):** Rigor na aplicação de anonimização e desenvolvimento do classificador com Python.
- **Profundidade de Análise (30%):** Capacidade de interpretar o trade-off privacidade/utilidade e métricas de deteção.
- **Qualidade dos Entregáveis (20%):** Organização do relatório e código.
- **Criatividade (10%):** Visualizações inovadoras e correlação de métricas.